晶体生成的研究演化

已有进展、六个挑战与四个研究方向

目标：生成更多低 E_{hull}、独特且新颖的晶体

文献截至 2026 年 10 月 10 日

研究目标与科学价值

在相同计算投入下，获得更多稳定、独特且新颖的材料。

稳定性 S　　相对声明的竞争相集合计算能量，严格稳定阈值为 $E_{hull} \leq 0$。

独特与新颖　　U衡量集合内去重，N衡量相对参考库的新颖性。SUN同时满足S、U和N。

条件生成　　在稳定发现的基础上，控制组成、结构关系或目标性质。

科学价值　　材料空间远大于数据库。生成模型需要把已有知识用于尚未记录的材料。

Materials Project (2013)；GNoME (Nature 2023)；MatterGen (Nature 2025)；强基线研究 (2025)

不同任务回答不同的问题

化学组成、原子占位和周期几何相互依赖，使晶体生成具有特殊难度。

任务	已知输入	需要生成	主要评价
结构预测 CSP	组成，有时含压力等条件	晶胞与原子位置	参考结构命中、低能结构
自主生成 DNG	训练数据与采样规则	组成及完整周期结构	S、U、N及SUN数量
条件生成	性质、对称或局部关系	满足条件的完整结构	条件命中及物理资格

同一组成可能对应多个晶型。几何合理之后，还需要判断相对竞争相的稳定性。

CDVAE (ICLR 2022)；DiffCSP (NeurIPS 2023)；MatterGen (2025)；Structure Matches (NeurIPS 2025)

领域沿三条研究线并行发展

新方法不断扩展可表达的结构、可接受的条件和可利用的物理信息。

研究线	早期基础	2023—2024	2025—2026
结构表示与生成	iMatGen、FTCP CDVAE	DiffCSP、FlowMM 晶体语言模型	OMatG、SymmCD CrysLLMGen、MCFlow
条件与科学知识	性质潜空间 给定组成	对称约束 语言条件与连续精修	MatterGen、SCIGEN PLaID++、组合条件
物理与多解发现	AIRSS、USPEX 材料数据库	通用势、GNoME RL搜索与晶体QD	物理后训练 层级探索与数据回流

时间按代表工作首次公开或正式发表概括。三条线之间不断交换方法。

代表文献见本报告备注及文献年表。并行关系为综述归纳。

周期生成开始直接建模晶体几何

工作	解决的主要困难	方法与已建立的能力
CDVAE ICLR 2022	周期结构的可学习生成	潜变量组织结构属性，周期去噪生成坐标。
DiffCSP NeurIPS 2023	给定组成下晶胞与坐标耦合	联合等变扩散，提高参考结构预测能力。
FlowMM ICML 2024	周期变量的连续生成路径	在晶体流形上进行 flow matching。
OMatG ICML 2025	离散元素与连续几何联合生成	随机插值（SI）结合连续几何与离散元素过程。

这些方法提供了联合生成工具。新的问题是它们如何学到未见化学与几何的正确配对。

CDVAE [R08]；DiffCSP [R13]；FlowMM [R26]；OMatG [R34]

对称性改变了模型能作出的结构选择

空间群和非等价位点减少自由度，也让生成器直接控制结构关系。

方法进展　DiffCSP++施加空间群约束。CrystalFormer、SymmCD和Wyckoff方法显式生成对称配置。

代表结果　SymmCD在10,000个候选中得到1,654种新模板，DiffCSP++为110种。

结果含义　该结果支持结构模板扩展。元素占位与相稳定性仍需通过学习和物理评价确定。

DiffCSP++ (ICLR 2024)；SymmCD (ICLR 2025)；WyckoffDiff / Wyckoff Transformer (ICML 2025)

语言模型与连续生成开始分工合作

语言模型提出化学和结构方案，连续模型改善坐标与晶胞。

代表工作	技术分工	留下的研究问题
CrystaLLM / Crystal-LLM 2024	从晶体文本学习结构与化学统计	文本怎样保留物理关系?
FlowLLM NeurIPS 2024	LLM提供初始分布，flow连续运输	怎样利用更好的初始结构?
CrysLLMGen NeurIPS 2025	独立LLM提案，再用diffusion精修	几何证据何时应修改元素?

FlowLLM与CrysLLMGen的连续阶段固定元素。双向修订具有明确的已有工作参照。

CrystaLLM [R12]；Crystal-LLM [R21]；FlowLLM [R29]；CrysLLMGen [R43]

条件生成已经覆盖多种科学要求

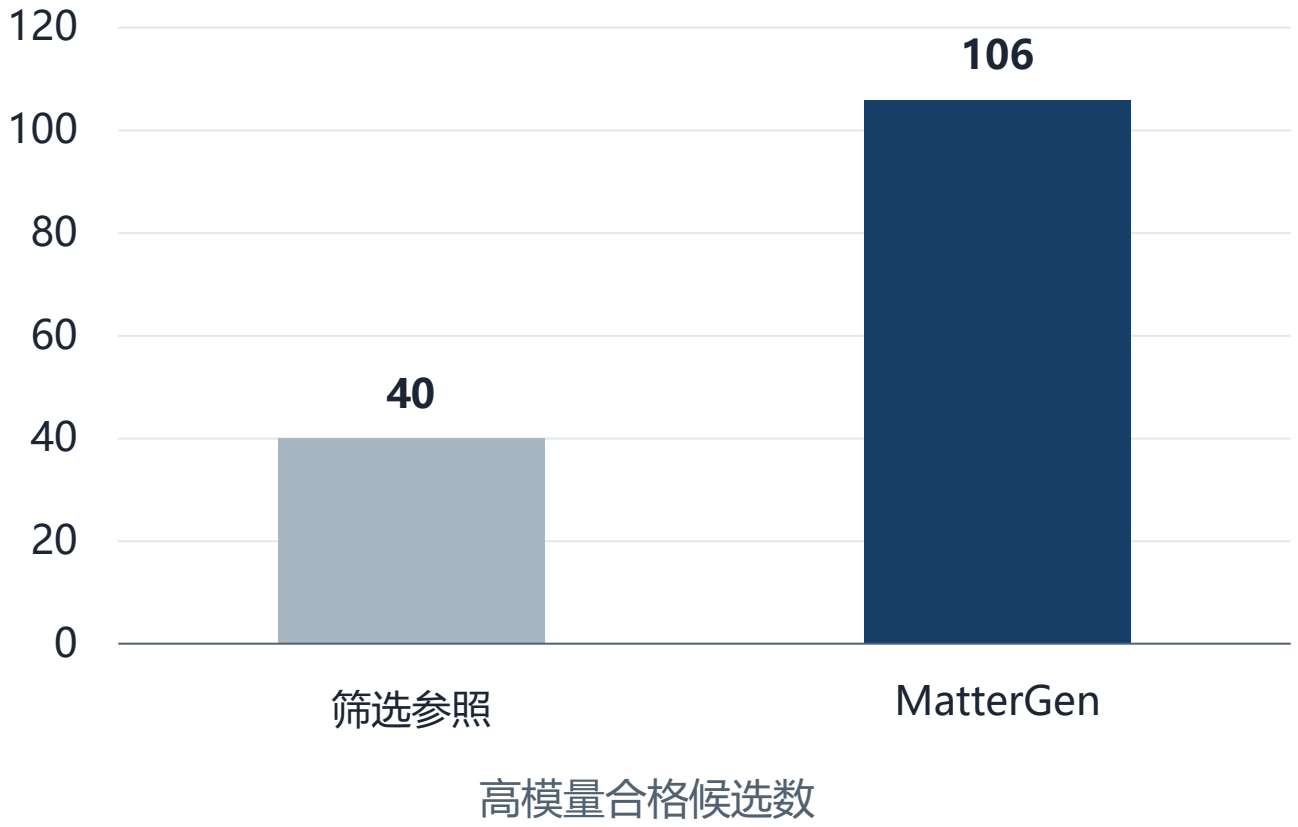
条件	代表工作	已实现的能力	当前困难
组成与性质	Con-CDVAE、MatterGen	给定性质或化学条件生成	稀疏目标与多目标兼容
对称性与结构图案	DiffCSP++、SCIGEN	固定部分结构关系	局部要求与整体稳定性
文本与知识	Chemeleon、PLaID++	用描述或结构语言控制	信息是否正确进入几何
多模态与组合	MCFlow、Composable Crystals	互条件生成与概念控制	未见条件组合的泛化

条件命中与稳定发现共同构成条件生成的评价目标。

MatterGen (2025)；SCIGEN (2025在线)；PLaID++ / MCFlow (ICML 2026)；Composable Crystals (预印本)

MatterGen展示了性质条件生成的价值

在180次DFT性质调用下，条件生成得到更多高模量合格候选。



方法

联合扩散模型通过适配训练接受目标性质。

结果

论文报告106个高模量SUN候选，筛选参照为40个。

口径

该文SUN允许 $E_{hull} \leq 0.1$ eV/atom。180次计入性质DFT调用。

MatterGen, Nature 639, 624–632 (2025)。数据按论文条件实验重绘。

SCIGEN把结构图案约束用于材料发现

指定功能相关结构后，模型生成周围的周期环境，再接受物理和实验检验。

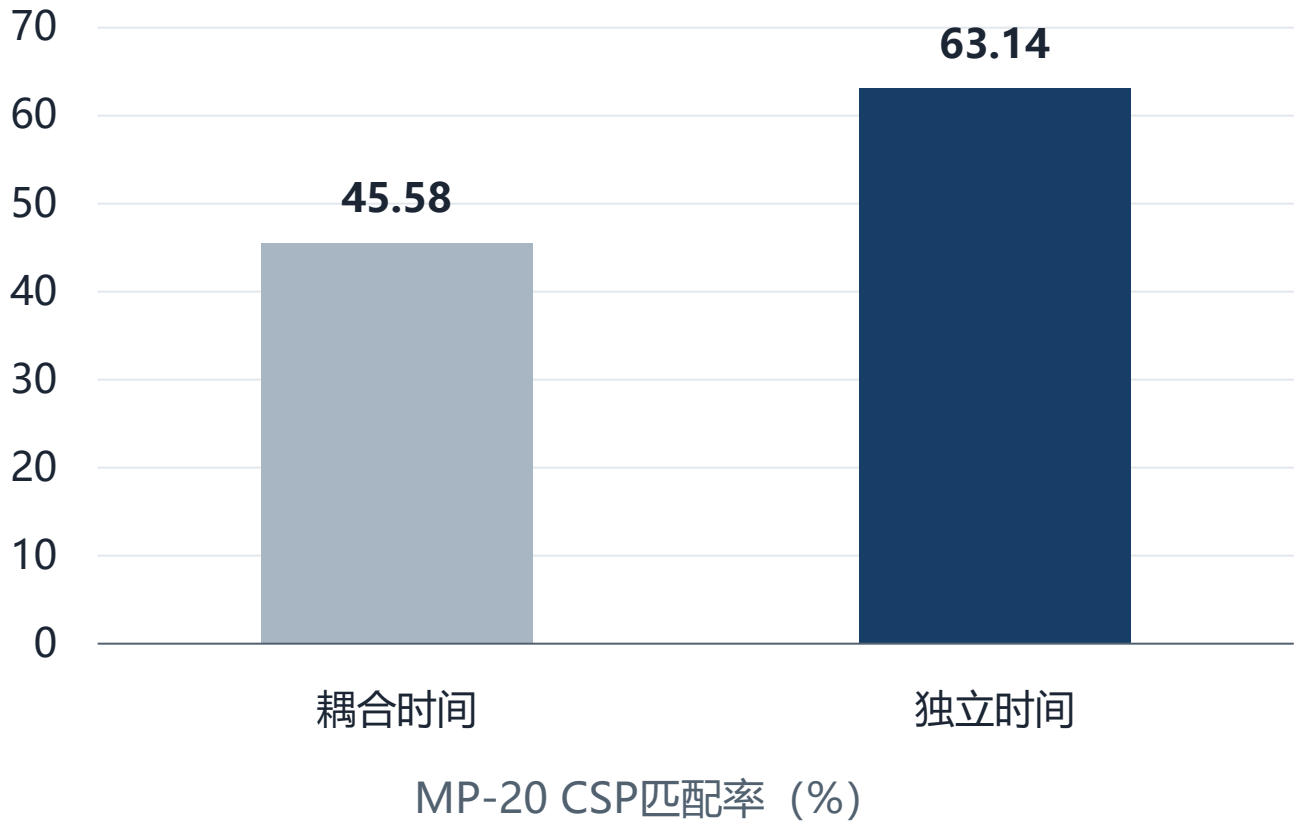
结果阶段	数量或实例	解释
DFT弛豫	26,000次尝试 24,743个输出	说明计算流程得到弛豫结构的比例。
残余力要求	13,880个	最大力 < 0.01 eV/Å，属于力收敛要求。
结构保持与新颖去重	5,931个小畸变结构 3,018个新颖去重结果	进一步加入结构保持及身份判断。
指导合成	$TiPd_{0.22}Bi_{0.88}$ $Ti_{0.5}Pd_{1.5}Sb$	提案帮助合成，实验计量和空间群有所改变。

残余力、结构保持、新颖性和凸包稳定性各自回答不同问题。

SCIGEN, Nature Materials (2025在线 / 2026卷期)，补充§10.1、§12、Table 3。

MCFlow研究化学与几何的信息进度

同一模型需要适应“哪些变量已知、哪些变量仍要生成”。



方法

不同模态分别控制信息进度，支持多种条件任务。

结果

附录H.8中，独立时间版本的CSP匹配率更高。

引出的疑问

哪些决定可以先确定，哪些需要后续信息帮助修订?

MCFlow, ICML 2026，arXiv v3，附录H.8。此处为CSP匹配率。

物理反馈已从评价进入模型学习

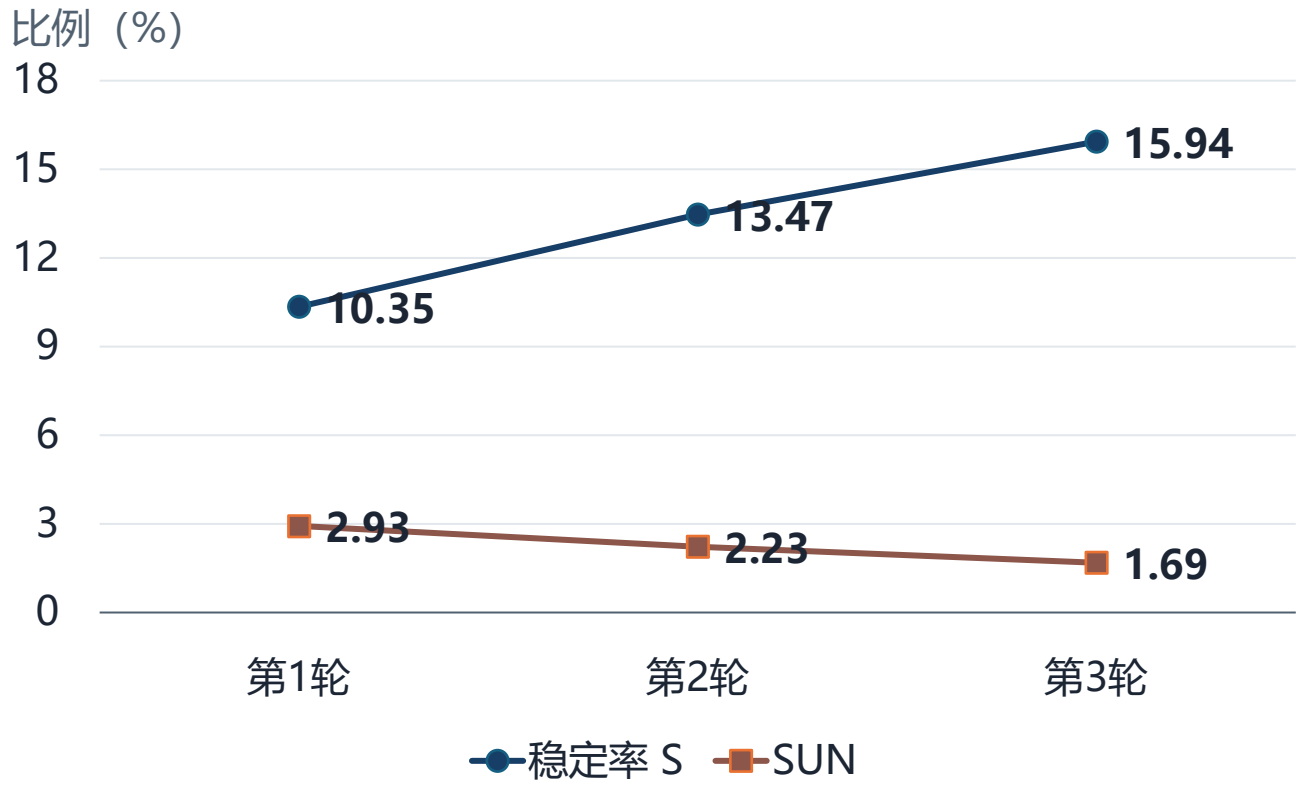
研究阶段	代表工作	物理信息如何发挥作用
结构搜索	AIRSS、USPEX、RL-CSP	评价候选，选择下一次结构变化。
数据积累	M3GNet、CHGNet、GNoME	扩大可计算范围，将新计算用于预测模型。
生成器后训练	MatInvent、PLaID++ Chemeleon2	用性质、偏好或物理资格改变生成分布。
连续生成过程学习	OMatG-IRL、OMatG-flash	把物理奖励用于生成场或少步生成映射。

下一步需要解释：模型学到的哪些物理关系能帮助新的材料和新的条件?

RL-CSP (2023)；PLaID++ / OMatG-IRL (ICML 2026)；Chemeleon2 (2026)；MatInvent / flash为预印本

稳定率提高时，SUN仍可能下降

PLaID++的坐标表示对照说明，稳定性收益可能同时伴随发现数量损失。



同一对照

稳定率由10.35%升至15.94%，SUN由2.93%降至1.69%。

科学问题

怎样让稳定性优化增加不同的新结构?

结果范围

该现象来自坐标表示消融。论文主方法研究表示与偏好学习。

PLaID++, ICML 2026，arXiv v4。每轮10,000个可解析CIF，eSEN评价，$E_{hull} \le 0$。

多解发现关注整个成功集合

一个材料设计请求往往需要多个不同答案，成功类别也很难预先列完。

已有方法 GFlowNet学习按奖励采样多个结果。晶体QD在性质空间保存不同的低能候选。

结构化探索 SHAFT用层级对称选择组织生成。ANCHOR依据搜索历史调整化学组成的探索。

剩余困难 弛豫可能合并原始差异。新增成功需要学入模型，已有成功也需要保持可采样。

GFlowNet Foundations (JMLR 2023)；晶体QD (2024)；SHAFT (2025在线)；ANCHOR v2 (2026预印本)

稳定发现的评价需要共同口径

必须说明的条件	为什么影响结论
稳定阈值与参考相集合	$E_{hull} \leq 0$ 与 ≤ 0.1 eV/atom对应不同的合格范围。
物理层级与弛豫流程	DFT和MLIP提供不同证据。弛豫可能改变能量和结构身份。
分母与完整费用	全部请求、可解析结构和完成评价的样本数需要分别保留。
新颖性与独特性	参照集合和匹配阶段决定N与U，原型新颖性可作为额外分析。

本项目主结果采用严格SUN。熟悉原型中的新稳定化学仍属于有效发现。

强基线研究 (2025)；Structure Matches (NeurIPS 2025)；LeMat-GenBench v2；替换新颖性分析 (2026)

项目历史实验为问题提供了哪些线索

观察	已完成结果	引出的研究问题
物理反馈可以改善终点	同512来源中，plain / restored / detached 已知稳定数76 / 85 / 86	哪些变化促成新增稳定终点?
动作变化未必增加成功	PDE18：128个DEV父来源，512配对 严格稳定 gain / loss = 0 / 0	反馈应支持什么有用决定?
稳定与SUN的差距	PDE22：86个稳定尝试，58个稳定新颖 最终53个独特SUN类别	稳定性、新颖性、重复各损失多少?

这些是项目已有观察。四个新方向的算法结果需要分别建立。

项目历史证据：crystal/evidence/historical-evidence.md。每臂能量未知状态保留。

挑战1与2：条件如何实现，决定如何修订

C1 科学要求怎样得到正确的物理结构?

性质条件、对称约束和语言描述已经能影响生成。

当前要解释：方案选择、条件传递与几何实现，哪一步限制了结果?

C2 互相依赖的决定何时确定?

联合扩散和多模态flow已经处理化学与几何依赖。

当前要解释：哪些元素或占位选择需要后续几何证据帮助修订?

两项挑战共同支持方向A：让化学选择与几何生成相互提供信息。

DiffCSP；MatterGen；FlowLLM；CrysLLMGen；MCFlow。挑战表述为综述综合。

挑战3：局部规律怎样组成周期整体

相邻环境共享原子、键和晶胞，各自合理的要求可能互相冲突。

已有基础　图模型与通用势学习局部环境。对称和概念条件让局部关系进入生成过程。

当前困难　局部配位需要满足整体计量、周期连接和应变要求，随后还要面对相竞争。

方向B的问题　模型能否把熟悉的局部知识用于新的化学或连接方式，并产生稳定整体？

CGCNN；M3GNet / CHGNet；SCIGEN；Composable Crystals；UFO-MGen（后两项为2026预印本）

挑战4与6：物理计算怎样帮助后续生成

C4 什么反馈能改变生成决定?

物理搜索、引导和强化学习已能改变生成或搜索结果。

困难在于将当前可计算的响应，对应到仍能改变终点的选择。

C6 一次计算能帮助多少新的材料?

数据回流与物理后训练已经改善模型。

需要识别可迁移的响应关系，并检验它能否超出成功端点记忆。

两项挑战共同支持方向C：学习结构变化与物理后果之间可复用的关系。

RL-CSP；GNoME；MatInvent；OMatG-IRL；GSS；OMatG-flash。

挑战5：怎样持续获得不同的合格结果

稳定性优化需要同时考虑新成功的出现与已有成功的保留。

已有基础　　GFlowNet、QD及层级搜索已经把多个有用结果作为目标。

当前困难　　合格类别通常未知。弛豫后才确认结构身份，搜索历史还会改变重复样本的价值。

方向D的问题　　怎样发现新成功、让模型学会生成它，并继续找到未用于训练的新结果？

C6同时进入这一方向：探索所得信息需要改善后续独立采样。

GFlowNet；晶体QD；SHAFT；Chemeleon2；ANCHOR。

六个挑战形成四个独立研究方向

方向	主要挑战	中心问题	优先技术基座
A 化学与几何共同生成	C1、C2	怎样根据彼此的证据修订选择?	LLM + Diffusion / SI
B 局部知识的整体实现	C3，联系C1	哪些共享条件支持新的组合?	组合条件 Diffusion
C 从物理反馈学习	C4、C6	哪些响应关系可以迁移?	SI / flow 路径学习
D 持续发现不同结果	C5、C6	怎样获得并保持新成功?	层级 LLM / AR + 条件 Diffusion

四个方向共享SUN目标，各自回答不同的学习问题。

研究议程。AR = autoregressive，自回归生成。SI = stochastic interpolants，随机插值。

方向A：化学选择与几何相互修订

问题：几何逐渐清楚后，模型怎样改进最初的化学选择?

方法 LLM组织元素、占位与结构关系。Diffusion或SI生成周期几何，中间结构信息再用于修订仍未确定的选择。

已有进展 FlowLLM和CrysLLMGen已有单向分工。MatterGen、OMatG与MCFlow提供联合生成参照。

需要的结果 在未见化学与结构组合上，检验配对正确性、有效修订和独立DNG的SUN增量。

主要比较：强组成提案+CSP，纯联合生成，双向交互。

方向A为待验证方法。先行：FlowLLM；CrysLLMGen；MatterGen；OMatG；MCFlow。

方向B：局部化学知识的整体实现

问题：哪些局部规律能在新的周期结构中同时成立？

方法 用组合条件Diffusion表示配位和周期连接要求，在共享原子位置与晶胞中生成完整结构。

已有进展 SCIGEN展示结构约束的用途。Composable Crystals等开始研究概念组合。

需要的结果 在新的化学、连接方式或原胞复杂度上，检验组合泛化及稳定结构增量。

主要比较：整结构模板、独立条件输入、显式共享关系。

方向B为待验证方法。先行：SCIGEN；Composable Crystals；UFO-MGen；CHGNet。

方向C：把物理反馈学入生成模型

问题：一次结构改变产生的响应，能否帮助其他材料？

方法 用SI或flow学习来源、实际结构变化、物理响应与多个终点的关系，将已付费计算用于后续生成。

已有进展 物理后训练已有成果。新贡献需要解释模型学到了何种可复用关系。

需要的结果 在相同物理投入下，检验跨条件迁移，以及普通独立采样产生的SUN增量。

主要比较：仅学成功终点、标量奖励训练、保留响应关系的学习。

方向C为待验证方法。先行：MatInvent；PLaID++；Chemeleon2；OMatG-IRL；OMatG-flash。

方向D：持续发现不同的稳定新结构

问题：生成分布怎样获得新成功，并保留已经学到的成功？

方法 层级LLM或AR组织化学与结构选择，条件Diffusion保留多种几何实现。根据物理结果和发现历史继续学习。

已有进展 GFlowNet、QD和ANCHOR已有多解与历史相关探索。

需要的结果 在同预算下，检验首次发现数量、新成功的再生成能力，以及后续新增发现。

主要比较：固定采样、只重采样已有成功、探索后持续学习。

方向D为待验证方法。先行：GFlowNet；晶体QD；SHAFT；ANCHOR。

四个方向应建立什么论文结果

方法成功需要同时带来可解释的学习进展和稳定新结构增量。

A的结果	说明化学与几何交换了什么有效信息，并在新组合上优于强分阶段方法。
B的结果	说明哪些共享关系使局部知识可以迁移，并形成新的稳定整体。
C的结果	说明物理响应中哪些内容能够复用，并改善后续独立生成。
D的结果	说明模型怎样获得和保留未知成功，并持续扩大不同的SUN结果集合。

共同结果口径：严格SUN、条件任务、独立来源、完整费用。新算法结果待建立。

主要参考文献：表示与条件生成

[R08] Tian Xie et al. Crystal Diffusion Variational Autoencoder for Periodic Material Generation. ICLR 2022.

[R13] Rui Jiao et al. Crystal Structure Prediction by Joint Equivariant Diffusion. NeurIPS 2023.

[R26] Benjamin Kurt Miller et al. FlowMM: Generating Materials with Riemannian Flow Matching. ICML 2024, PMLR 235.

[R34] Philipp Hoellmer et al. Open Materials Generation with Stochastic Interpolants. ICML 2025, PMLR 267.

[R35] Daniel Levy et al. SymmCD: Symmetry-Preserving Crystal Generation with Diffusion Models. ICLR 2025.

[R19] Claudio Zeni et al. A generative model for inorganic materials design. Nature 2025.

[R27] Ryotaro Okabe et al. Structural constraint integration in a generative model for the discovery of quantum materials. Nature Materials 25, 223–230 2026.

正文各页备注包含对应原文链接与结果范围。完整57项文献见综述索引。

主要参考文献：交互、反馈与发现

[R29] Anuroop Sriram et al. FlowLLM: Flow Matching for Material Generation with Large Language Models as Base Distributions. NeurIPS 2024.

[R43] Subhojyoti Khastagir et al. LLM Meets Diffusion: A Hybrid Framework for Crystal Material Generation. NeurIPS 2025.

[R40] Andy Xu et al. PLaID++: A Preference Aligned Language Model for Targeted Inorganic Materials Design. ICML 2026.

[R49] Kiyoung Seong et al. Multimodal Crystal Flow: Any-to-Any Modality Generation for Unified Crystal Modeling. ICML2026, PMLR306:109105–109131.

[R48] Philipp Hoellmer et al. Open Materials Generation with Inference-Time Reinforcement Learning. ICML 2026.

[R45] Hyunsoo Park et al. Guiding Generative Models to Uncover Diverse and Novel Crystals via Reinforcement Learning. Nature Machine Intelligence 2026.

[R56] Emma Lei Hovmand et al. Let CSP Be Your ANCHOR: Adaptive Crystal Search over Frozen Structure Priors. arXiv 预印本 2026.