晶体生成：数据、模型与验证

面向AI研究者的补充篇

晶体表示与数据集 · 评价指标与物理计算 · MatterGen五页详解

2026年10月13日

模型生成的是一个周期结构

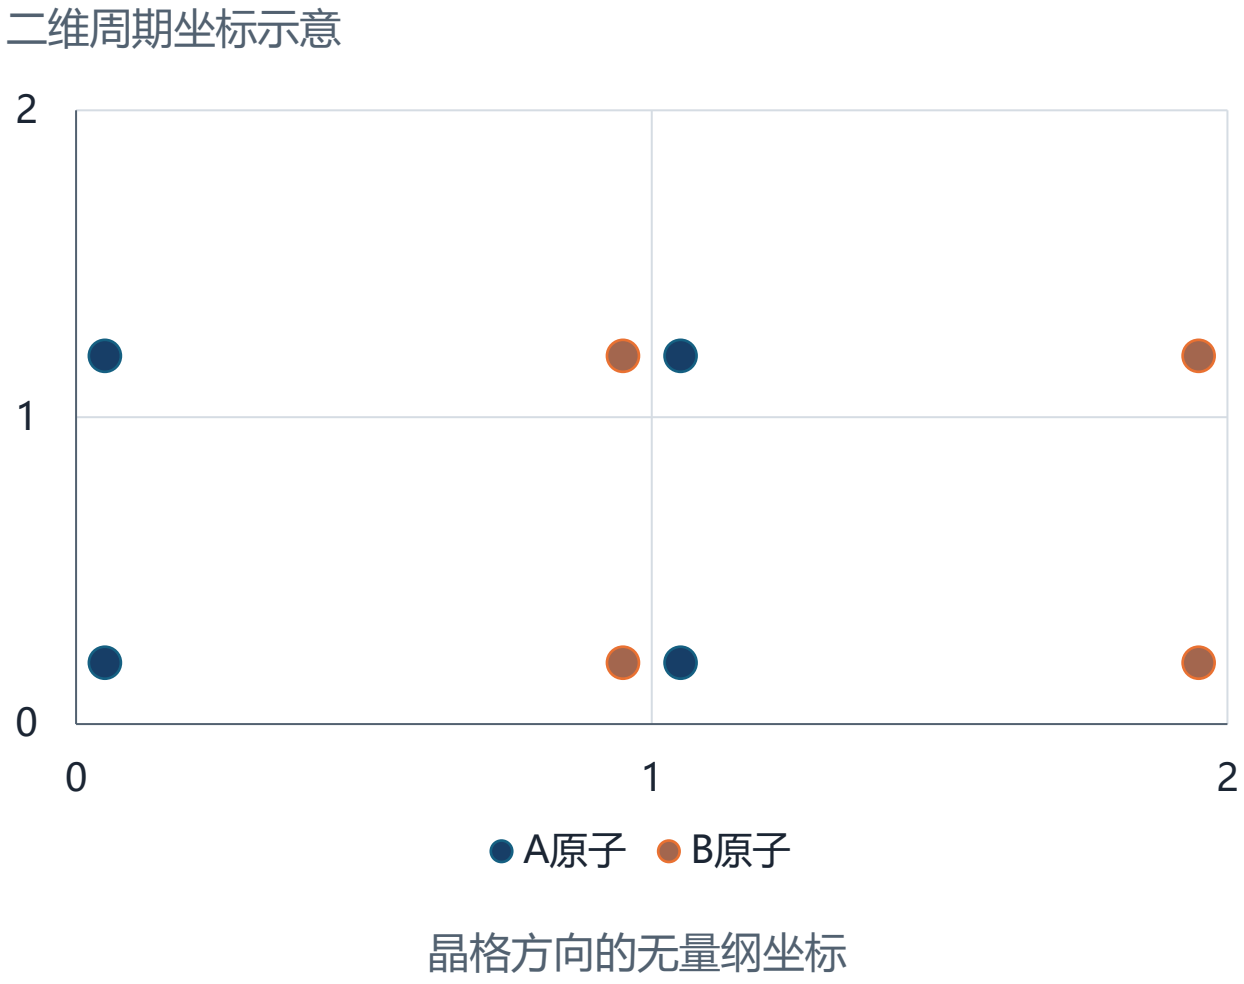
一个晶体可以表示为 $C = (A, F, L)$，原子数 n 也可能需要生成。

变量	数学表示	物理含义
元素 A	每个位点的元素类别	组成相同，原子排布仍可以不同
分数坐标 F	$f_i \in [0, 1)^3$	以晶格三条基矢表示原子位置
晶格 L	$L = [a \ \ b \ \ c]$	决定晶胞大小、形状与角度
周期复制	$r_{i,m} = L(f_i + m)$，$m \in \mathbb{Z}^3$	有限胞内原子重复形成三维体材料

CIF保存结构及晶体学信息。生成CIF后，还需要计算能量、性质和结构身份。

CDVAE §3；DiffCSP §3–4；IUCr晶体学定义。这里采用晶格列向量约定。

同一个晶体可以有多种编码



周期边界

f与f+m对应周期等价位置。0.99与0.01在胞边界两侧可以很近

几何等价

原子顺序、整体平移、旋转和晶胞选择都能改写输入

对称表示

空间群操作展开非等价原子。Wyckoff位置记录对称位点的重复数与自由坐标

左图为二维周期教学示意。真实晶体为三维。结构匹配需要处理物理等价关系。

先区分CSP、自主生成与条件设计

任务	给模型什么	模型需要输出	通常怎样评测
结构预测 CSP	组成或化学式	晶胞与原子位置	参考命中、RMSD、多晶型
自主生成 DNG	随机种子或噪声	组成与完整结构	有效率、S/U/N、SUN
条件生成	性质、元素范围、空间群或图案	满足要求的完整结构	条件命中与物理资格交集
物理预测	完整原子构型	能量、力、应力或性质	误差、动力学与应用表现

化学系统条件如“Li–O”允许选择计量；给定“Li_2O”则固定了更具体的组成。

任务输入不同，匹配率、性质命中率与材料发现率回答不同问题。

数据库、训练集与参考库各有用途

资源	主要内容	在生成研究中的作用
Materials Project	DFT结构、能量及性质	衍生训练集、竞争相和评价参考
Alexandria / OQMD	高通量DFT及假想结构	扩大化学覆盖，提供相能量
ICSD	整理后的无机结构，主要来自实验	已知材料与新颖性参考，含无序占位
COD	开放CIF，覆盖多类晶体	结构与文献来源，能量标签需另配

数据库会更新；模型实际使用的是某次下载、过滤和划分后的固定快照。

数据类型与用途来自各数据库原始论文或官方说明。总库规模不等于训练样本数。

常用生成基准各自检验什么

基准	固定规模	结构范围	用途与划分
Perov-5	18,928	ABX_3型，每胞5原子	组成变化为主；60/20/20
Carbon-24	10,153	仅C，6–24原子，10 GPa	结构与多晶型；60/20/20
MP-20	45,231	89种元素，输入胞≤20原子	组成与结构；60/20/20
MPTS-52	40,476	输入胞≤52原子	按时间划分 27,380 / 5,000 / 8,096

MP-20是特定基准文件和预处理流程，不等于现在查询所有“≤20原子”的MP结构。

CDVAE §5 / Appendix C；DiffCSP §5 / Appendix F。比例依次为训练、验证、测试。

生成终态数据与势能轨迹数据不同

生成器学习哪些结构会出现，MLIP还要学习离开终态后能量怎样变化。

生成训练集	一条记录通常是一种结构及可选性质。Alex-MP-20将生成训练扩展到数十万结构
MLIP轨迹集	同一材料的弛豫过程包含多帧，每帧带能量、力和应力。MPtrj约158万构型来自约14.6万材料
划分单位	CHGNet按材料划分80/10/10，避免同一材料的相邻帧跨训练和测试
复现信息	记录数据版本、计算口径、过滤和划分。构型数、材料数、模型参数量分别报告

MPtrj：MP 2022年9月快照，1,580,395构型。MatterGen训练数据将在第23页展开。

常见生成模型的技术分工

模型家族	代表工作	直接生成什么
潜变量与周期去噪	CDVAE	先组织全局结构属性，再生成元素与坐标
Diffusion	DiffCSP、MatterGen	对晶格、周期坐标及可选元素联合去噪
Flow / SI	FlowMM、OMatG	学习连接初始分布与晶体分布的连续过程
语言与混合生成	Crystal-LLM、FlowLLM CrysLLMGen	序列化结构；或用LLM提案接连续精修
对称与多模态	SymmCD、MCFlow	生成非等价位点，或完成元素与几何的互条件任务

SI = stochastic interpolants。不同范式可组合，比较时保留任务输入。

代表论文怎样连接数据、模型和评测

工作	数据与任务	主要评测对象
CDVAE	Perov-5 / Carbon-24 / MP-20 重构与DNG	有效率、指纹覆盖、性质分布
DiffCSP / FlowMM	MP-20等，组成CSP与DNG	CSP匹配/RMSD；DNG另做物理评价
FlowLLM / CrysLLMGen	MP-20为主，混合DNG	前者报告DFT-SUN，后者主要CHGNet评测
MatterGen	Alex-MP-20，DNG与条件设计	统一DFT弛豫、SUN、性质及实验案例
Chemeleon2	MP-20 / Alex-MP-20 DNG与性质后训练	代理势评价与选定DFT，含性质交集指标

这是评测方式对照表。不同评价器、阈值与分母的SUN数值不构成统一排行榜。

生成器与MLIP承担不同工作

MLIP学习势能面；优化器使用它给出的力与应力更新结构。

物理模型	主要训练信息	典型用途
M3GNet	MP弛豫中的能量、力、应力	结构弛豫、筛选与材料模拟
CHGNet	MPtrj，加磁矩相关监督	电荷环境相关表示、弛豫与动力学
MACE-MP-0	等变多体网络，MPtrj	能量及导数、弛豫与MD
MatterSim-v1	离平衡与温压采样数据	更广物理状态下的预测与计算

物理输出包括 E、$F = -\nabla_r E$ 和应力。记录实际checkpoint及标签口径。

能量常报eV/atom，力报eV/Å，应力报GPa。MAE只对相应测试分布有意义。

一次生成实验包含哪些计算

步骤	得到什么	应记录的费用或数量
提出与有效性检查	原始结构、可计算候选	请求数、失败数、采样步数与硬件
结构弛豫	局部低能终态及收敛状态	MLIP/DFT调用、优化步数、资源小时
能量与结构匹配	稳定资格、U/N/SUN	竞争相参考、匹配规则、未知状态
性质与物理复核	功能性质、声子或迁移等	被选样本数、计算参数、筛选分母
实验材料	实际产物、结构与性质	尝试数、纯度、表征与测量条件

发现费用还包含数据、训练、失败重试和参考相计算；DFT性质调用只是其中一项。

顺序按研究目的调整。原始生成、MLIP终态和DFT终态分别记录。

Validity先判断候选能否继续计算

检查	具体对象	结果含义
可读取与晶胞合法	CIF、元素、占位、晶格体积	得到完整且可解析的结构
几何有效性	周期最小距离、密度、异常晶格	排除严重碰撞或畸形结构
组成有效性	允许氧化态与电荷平衡等规则	符合所采用的化学启发式
规则示例	SMACT可寻找 $\Sigma_e n_e q_e = 0$ 的赋值	NaCl可用Na^+和Cl^-解释电荷平衡

通过有效性检查后，再评价相稳定性和目标性质。

阈值随协议变化：CDVAE距离阈值0.5 Å，LeMat-GenBench采用0.7 Å及额外检查。

CSP评测：参考命中率与几何误差

MR@k = 命中至少一个参考结构的测试请求数 / 全部测试请求数

匹配	处理原子重排、平移和晶胞等价后，按晶格、角度及位置容差比较
RMSD	匹配原子的位移均方根。文献可能报Å，也可能除以 $(V/n)^{1/3}$ 归一化
采样预算	MR@20通常允许每个组成20个候选。best-of-k评测可用参考答案选最好者
多晶型	同一组成可能有多个低能结构，单个数据库参考不代表全部可行答案

DiffCSP §5.1；pymatgen StructureMatcher。匹配率应与成功匹配集上的RMSD一起读。

分布指标衡量覆盖与偏移

指标	如何计算或理解	它描述什么
COV-Recall	参考集合中被生成指纹邻域覆盖的比例	生成集合覆盖了多少参考变化
COV-Precision	生成集合中靠近参考指纹分布的比例	有多少输出处于参考邻域
JSD	两个类别分布的对称差异	元素、空间群等分布偏移
Wasserstein-1	将一份标量分布搬成另一份的平均距离	密度、能量等性质分布差异

这些指标描述统计分布；稳定新材料还需要结构匹配及物理资格。

COV依赖结构/组成指纹与阈值；W_1保留性质单位。SciPy的Jensen–Shannon函数返回JSD的平方根。

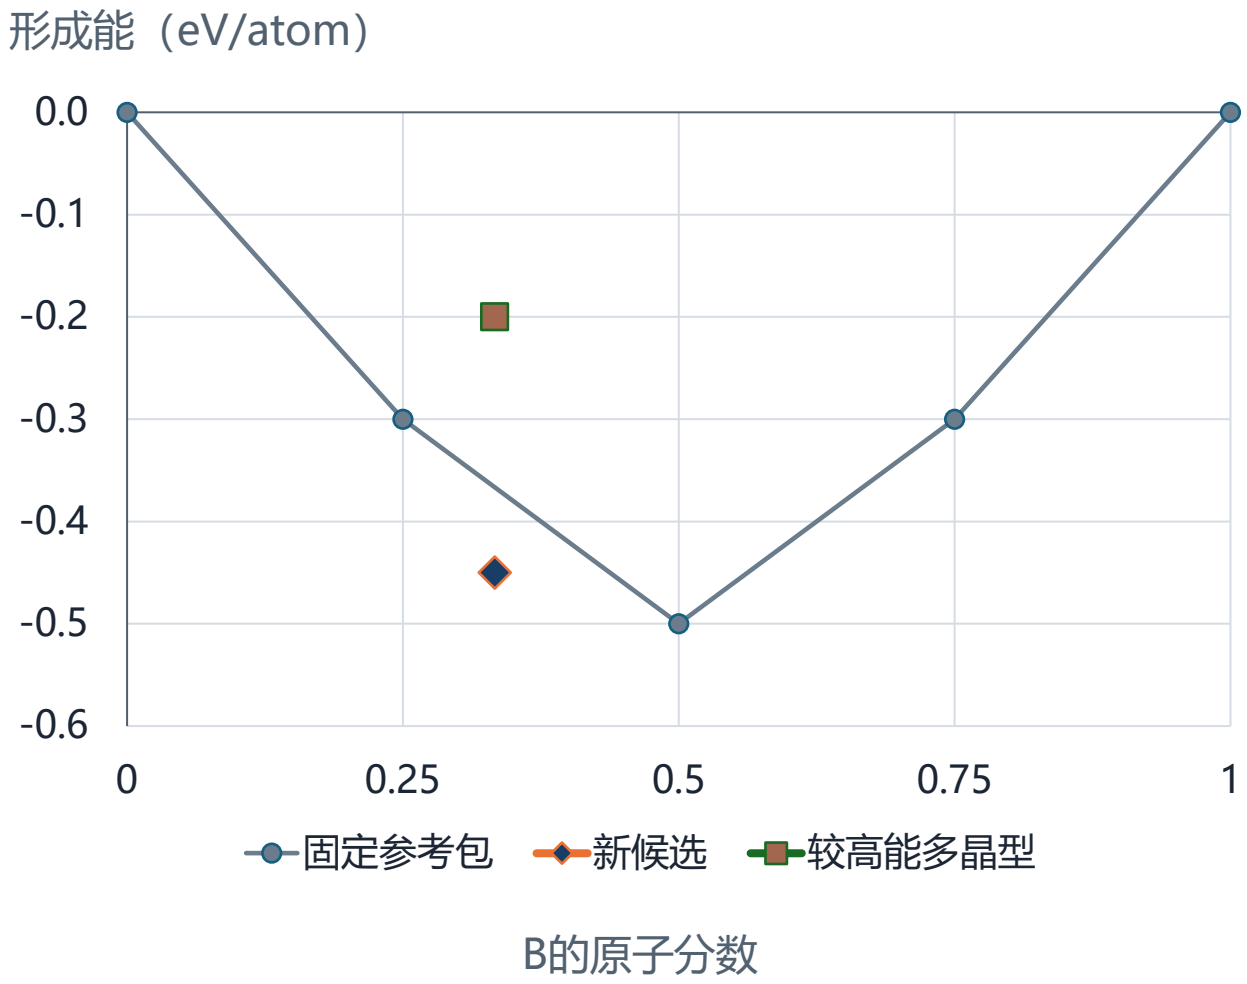
形成能和凸包能比较不同的竞争对象

$$E_{form} = (E_{cell} - \Sigma_e n_e \mu_e) / n$$

形成能	比较化合物与对应元素参考相。单位通常为eV/atom
相分解	即使形成能为负，也可能更愿意分解成若干更低能化合物
凸包	在组成守恒下，求参考相混合所能达到的最低能量
物理条件	常见电子能凸包近似0 K条件；压力下比较焓，有限温度平衡需要自由能

μ_e为元素参考的每原子能量。候选、元素端点与竞争相应使用相容的能量口径。

凸包能量差的两种口径



固定参考包

ΔE_ref = 候选形成能 − 参考包能量。它可为负，表示降低旧参考包

高于凸包的能量

把候选也加入相集合后，E_above hull ≥ 0；位于凸包上的结构为0

教学算例

A_2B能量−0.450，旧包为−0.3667 eV/atom，ΔE_ref = −0.0833

虚构二元体系教学图，非实验数据。加入候选后，它的标准E_above hull为0。

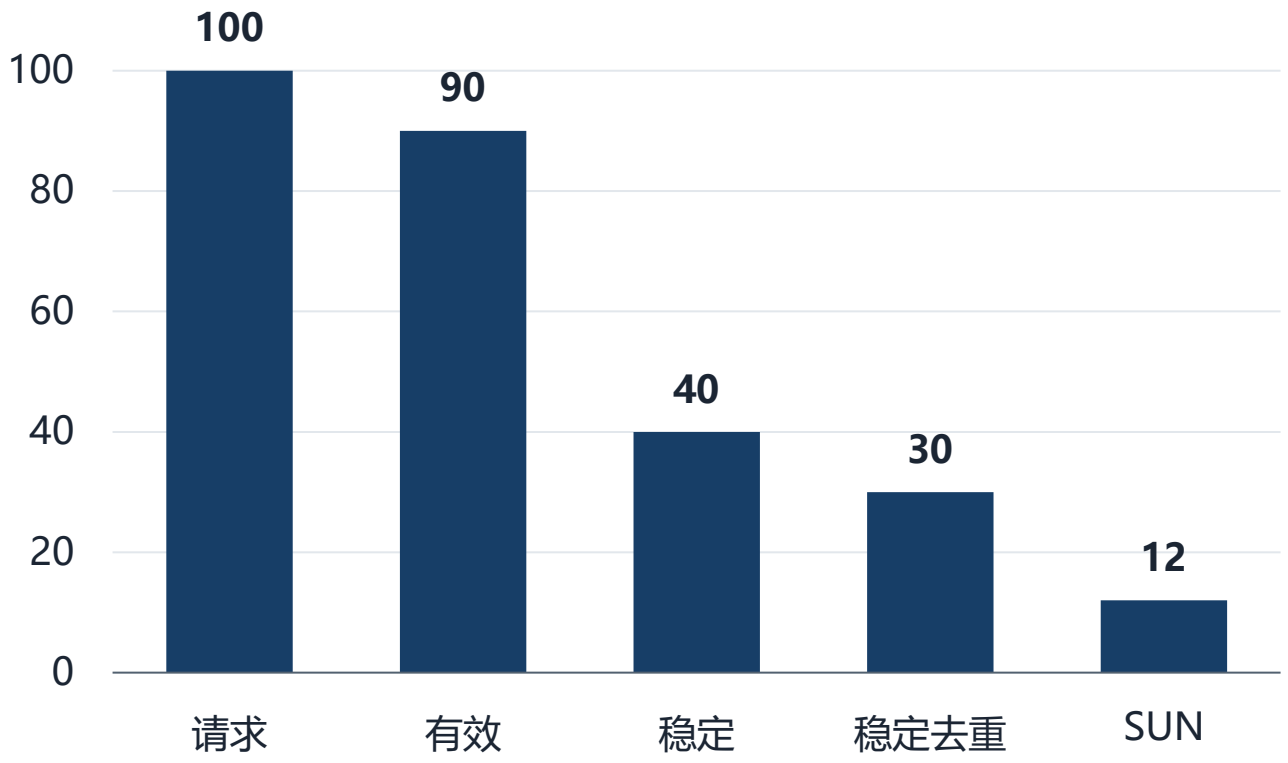
S、U、N与SUN分别回答什么

指标	计算对象	需要声明的条件
Stable，S	达到稳定或近凸包阈值的结构	阈值、评价器、能量参考、弛豫阶段
Unique，U	一批结果中去重后的不同结构	匹配容差、聚类顺序、代表选择
Novel，N	与固定参考库不匹配的结构	参考库版本、化学和结构匹配规则
SUN	稳定且新颖的结果去重后的数量或比例	完整交集和分母，不假定各项独立

新化学可以沿用熟悉结构原型。参考库外、训练集外和项目首次发现是不同概念。

论文“Stable”可能允许≤0.1 eV/atom。严格on-hull和近凸包结果应分别读。

SUN的分母与去重：一个算例



全部请求

100个提案，90个通过有效性检查

稳定与去重

40个确认稳定，去重剩30个不同稳定结构

新颖交集

其中12个不在参考库，SUN = 12/100 = 12%

条件比例相乘可还原漏斗；全体S、U、N的边缘比例不能直接相乘。

DFT在计算什么，为什么有不同结果

固定原子时求电子密度；得到能量、力和应力后，再决定是否更新结构。

计算设置	含义	影响
泛函、Hubbard U	电子交换关联及局域电子近似	相对能量、带隙与磁性
赝势 / PAW	核电子与价电子表示	能量基准与数值精度
k点与平面波截断	布里渊区积分与基组大小	能量、力和应力收敛
磁性、SOC与收敛标准	电子状态及计算精度	可能收敛到不同电子或磁性解

一次DFT弛豫含多次电子自洽计算。比较相稳定性时，候选和参照必须相容。

DFT = density functional theory；SCF = self-consistent field。参数取值应随目标与协议说明。

弛豫是在寻找局部低能结构

方式或工具	优化什么	应报告什么
固定晶胞	原子位置	原子最大力、步数、是否收敛
变胞弛豫	原子位置与晶胞形状/体积	力、应力、外压和约束
FIRE / L-BFGS	使用能量及梯度作局部优化	优化器、阈值、最大步数
MD / AIMD	按运动方程推进时间	温度、系综、步长与物理时长

FIRE的200步是优化工作量；MD的10,000步×1 fs才对应10 ps模拟时间。

教学时间算例。不同提案可能弛豫到同一终态，因此后处理也会改变U和N。

MLIP与DFT怎样配合评价

先用低成本势处理大量候选，再围绕论文主张选择DFT与性质复核。

标签一致	MLIP可能学习raw或已修正能量。候选、元素参考和竞争相必须处于相容尺度
具体例子	CHGNet原MPtrj权重学习已做MP2020修正的能量，重复加同一修正会再次移动能量
自洽凸包	可用同一MLIP计算候选和竞争相，再构造参考包；模型外推误差仍需研究
DFT复核	记录选样规则、原始分母与失败。随机核验、阈值附近核验和高分筛选回答不同问题

固定组成的能量常数修正不改变原子力，但会影响跨组成的相能量比较。

功能与物理稳定性怎样进一步计算

科学问题	计算或测量	得到的证据
小扰动是否失稳	声子：二阶力常数与频率	集体微扰的动力学稳定性
刚度及机械响应	应变—应力，弹性张量 C_{ij}	体模量、剪切模量及机械稳定条件
有限温度下的行为	MD / AIMD，给定温度与时间	该窗口内的结构保持或扩散
离子迁移或结构转变	NEB / CI-NEB寻找路径与鞍点	指定端点之间的激活势垒
电子与实际材料性质	能带 / DOS；XRD、成分及物性测量	计算功能与实验产物的相应证据

每项计算回答一个具体问题。低凸包能、无虚频、短时MD保持与实际合成各有含义。

围绕目标选择计算，并报告泛函或势、超胞、温压、时长及收敛条件。

MatterGen 1/5：问题、数据与训练对象

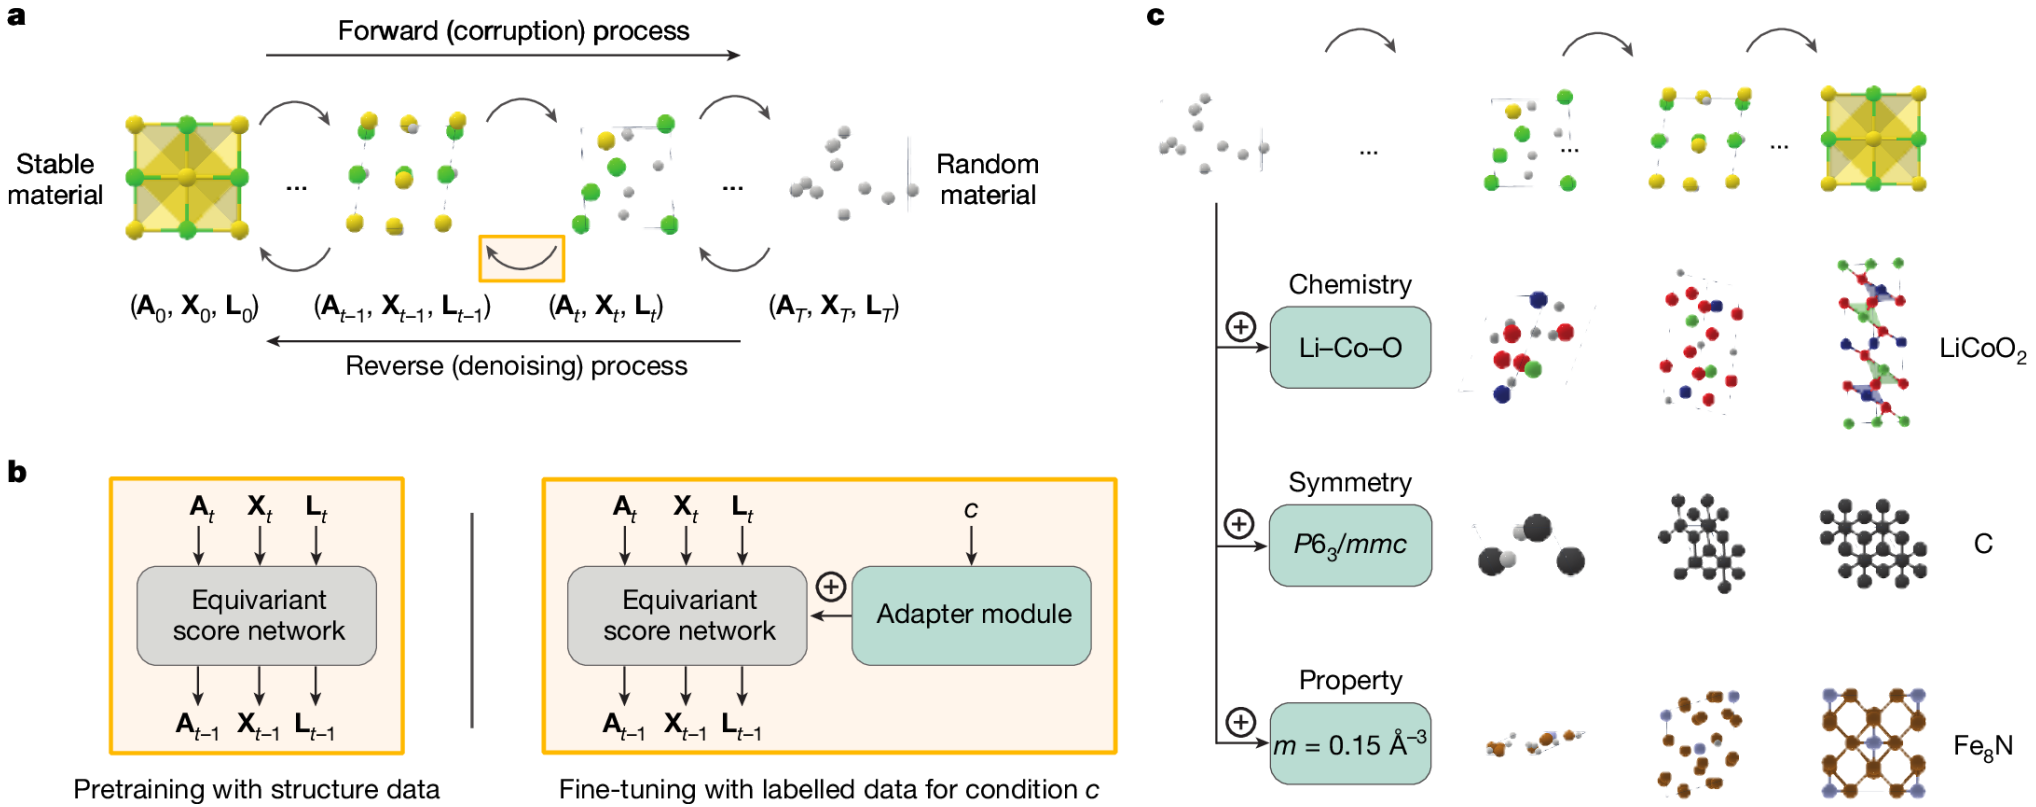
目标是在元素、位置与晶胞上联合生成，并用科学条件改变生成分布。

环节	正式论文采用什么	为什么这样做
预训练数据	607,683个Alex-MP-20训练结构 输入胞≤20原子，近凸包过滤	联合学习化学与结构分布
能量对齐	MP + Alexandria，非MP结构 按MP PBE(+U)流程重算	把不同来源放到可比较的能量尺度
稳定性参考	850,384个有序参考结构	计算相竞争的固定参考凸包
新颖性参考	上述结构再加117,652个 无序ICSD结构	考虑实际已知材料和占位无序

这是特定训练和参考快照。完整公开Alex-MP-20的675,204条与训练分区不同。

Zeni et al., Nature 639, 624–632 (2025)，正文与SI C。MatterGen是Nature主刊论文。

MatterGen 2/5：联合扩散与条件适配



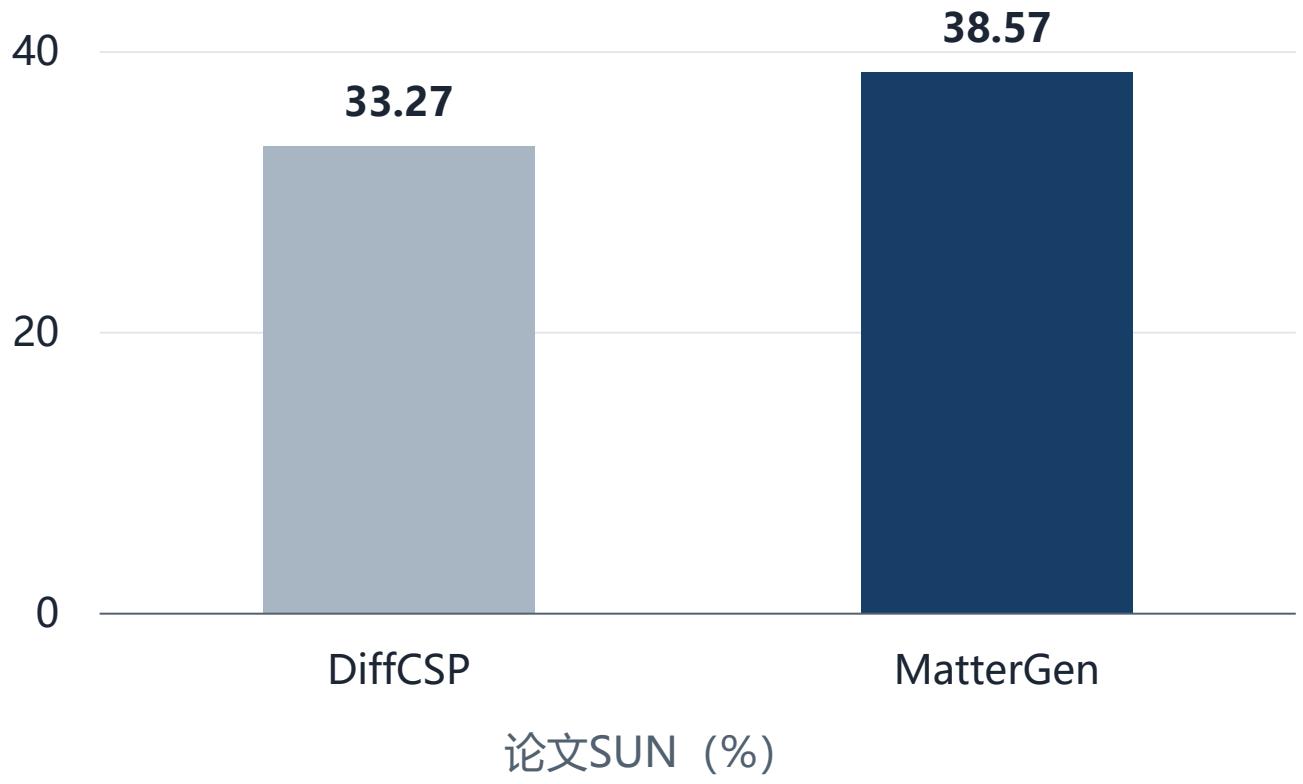
建模 元素用吸收mask噪声，位置用周期噪声，晶格用连续噪声；GemNet-dT联合预测去噪

训练与控制 条件经adapter注入，微调全部网络权重。采样用classifier-free guidance，保持周期结构表示

原图：MatterGen Fig.1。基础模型8×A100训练；正式微调更新全部模型权重。

MatterGen 3/5：无条件生成怎样评测

相同Alex-MP训练范围下，用DFT弛豫后的结构评价SUN。



评测链

1,024个样本经DFT弛豫、能量比较与结构匹配。

结果

约75%在参考凸包0.1 eV/atom内，约3%低于固定参考包。

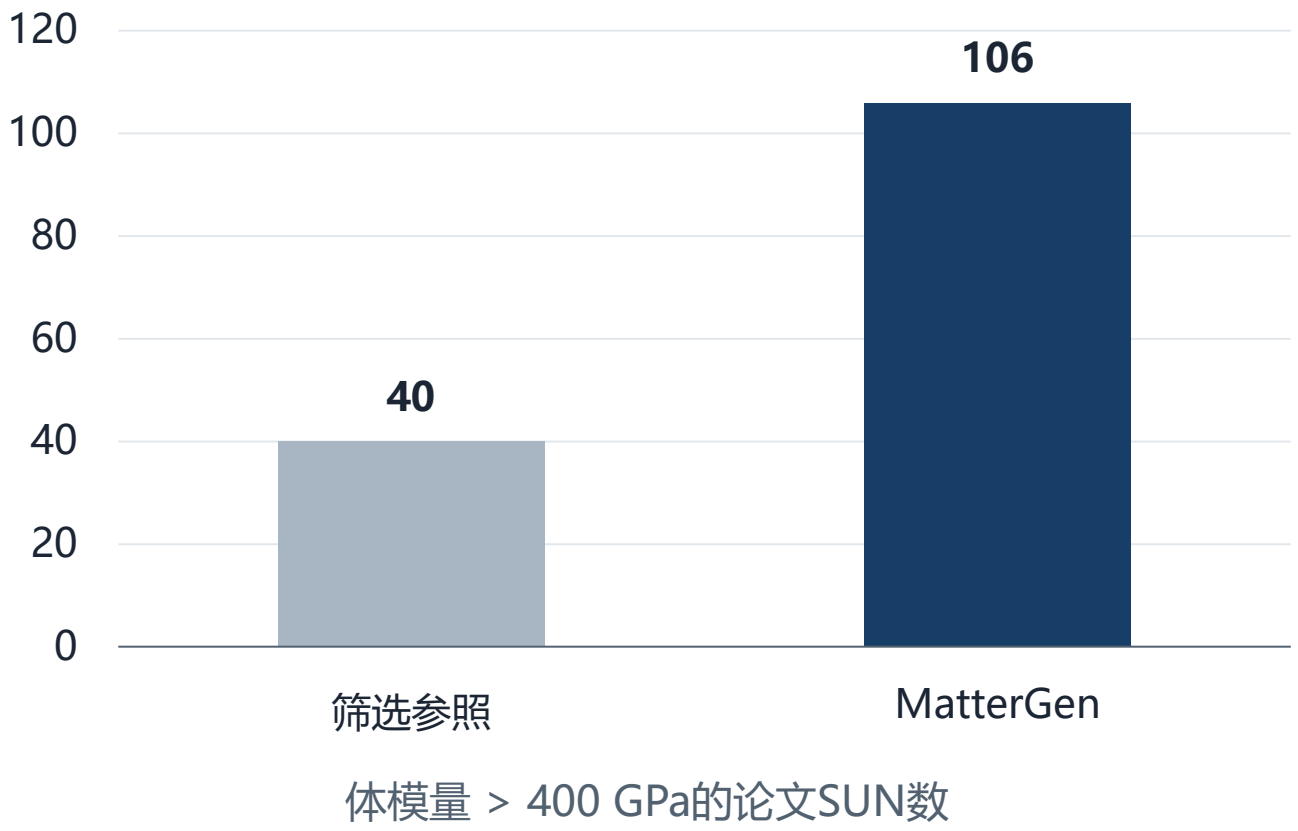
解释

Table D4的SUN为38.57%，生成到弛豫终态的RMSD为0.021 Å。

数据：SI Table D4 / Fig.2。稳定阈值允许≤0.1 eV/atom；不是全部严格on-hull。

MatterGen 4/5：条件设计如何验证

性质条件的价值，用满足目标且物理合格的候选数量检验。



体模量 > 400 GPa的论文SUN数

条件与标签

磁性约60.5万、带隙约4.2万、体模量约5,000个标签，分别用于对应任务。

计算对照

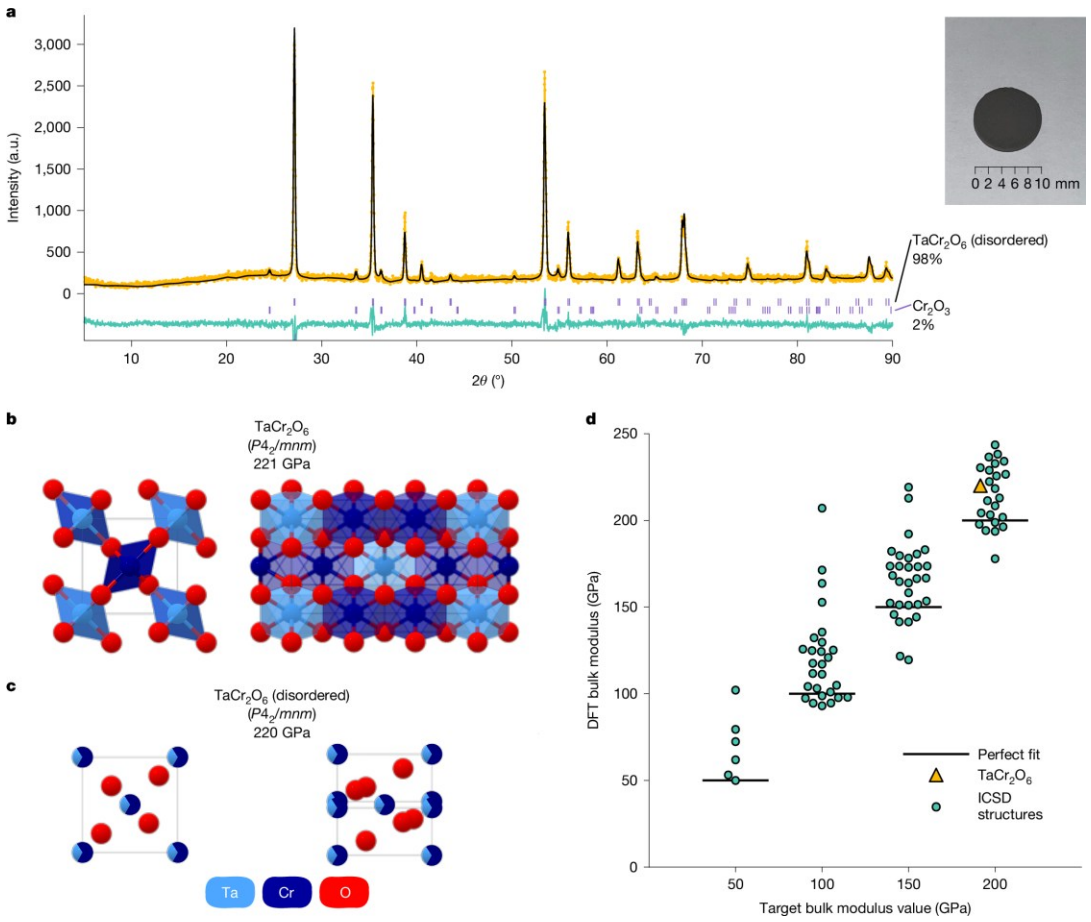
同一预测器辅助，180次DFT性质调用：MatterGen获得106个，筛选参照40个。

代价范围

原文预算轴只统计性质调用。训练、筛选与DFT弛豫另计。

MatterGen Fig.4h；稳定资格仍采用论文阈值。400 GPa设计任务与下页200 GPa实验目标不同。

MatterGen 5/5：计算怎样连接实际实验



筛选过程

32,768个提案逐级筛到75个DFT候选，选四个尝试，原文报告一个产物

结构与成分

原文将产物拟合为约98%无序$TaCr_2O_6$，另有约2% Cr_2O_3

功能测量

目标200 GPa，DFT约222。实验换算体模量158±11 GPa，最高169 GPa

纳米压痕测Young模量，K = Y / [3(1−2ν)]
泊松比ν=0.30取自DFT计算

原图：Zeni et al., Nature 2025, Fig.6（CC BY 4.0）。
2026年Materials Horizons再分析对产物身份及数据重合提出质疑，具体归属与证据见备注。

NMI及相关期刊中的两类模型贡献

论文	模型与数据	主要评测与科学结果
Chemeleon2 NMI 2026	latent Diffusion + GRPO MP-20 / Alex-MP-20	10,000个原始样本做MACE评测；选择性DFT与带隙交集，无新合成
CHGNet NMI 2023	磁矩相关监督的通用势 MPtrj弛豫数据	E/F/应力误差，MD及电荷相关应用；与DFT和已有实验比较
M3GNet Nature Computational Science	三体图网络通用势 MP弛豫数据	约3,100万假想结构筛选，优先2,000个DFT核验，并开展声子等计算

前者研究怎样提出目标材料，后者研究怎样可靠计算结构响应。论文主张决定验证方式。

NMI = Nature Machine Intelligence。这些是各论文实际采用的证据组合。

相关子刊怎样增加材料层面的证据

工作与期刊	核心问题	在生成指标之外做什么
SCIGEN Nature Materials	把功能图案嵌入晶体	DFT能带、合成探索、XRD及实际产物的磁性与电阻
Chemeleon Nature Communications	文本条件探索化学空间	MACE预筛、DFT相图，选定Li_2PS_3做声子；无新合成
SLICES Nature Communications	周期结构的可逆图表示	重构、逆设计、最终14个计算直接带隙候选；无新合成
CrystaLLM Nature Communications	CIF自回归与引导搜索	语法及结构指标，选择新颖子集做DFT；无新合成

这些案例把算法改善连接到具体材料问题，并明确计算候选与实际产物分别是什么。

SCIGEN 2025在线 / 2026卷期；Chemeleon 2025；SLICES 2023；CrystaLLM 2024。

阅读与复现的关键来源

任务与基准	CDVAE、DiffCSP、FlowMM的原文与官方数据配置
数据与相稳定	Materials Project方法文档、Alexandria发布页、pymatgen相图与结构匹配
物理计算	CHGNet / MACE / MatterSim模型资料；ASE与Phonopy方法说明
MatterGen	Nature正式论文、补充材料与官方代码。五页所引数据和原图各有来源位置

完整逐页来源与讲稿另附可检索文档。论文版本、训练快照与开源默认评测分别记录。